

信息论与编码

——编码理论

方伟军

网络空间安全学院

2026 春季学期

目录

教师基本信息

- 姓名：方伟军
- 研究方向：编码理论、分布式存储编码
- 办公室：淦昌苑 D326
- 手机号：13820905752
- 邮箱：fwj@sdu.edu.cn

- 《Essential Coding Theory》，Guruswami 等
- 电子书链接：
<https://cse.buffalo.edu/faculty/atri/courses/coding-theory/book/>

参考书

- 《Coding Theory A First Course》, S. Ling and C. Xing
- 《信息论与编码理论》, 沈世镒、陈鲁生
- 《编码理论基础》, 沈世镒、陈鲁生
- 《Introduction to Coding Theory》, Ron M. Roth
- 《The Theory of Error-Correcting Codes》, F. J. MacWilliams and N.J.A. Sloane

目录

- 通信 $\longleftrightarrow$ 编码

Morse Code（摩尔斯电码）

为什么学习编码理论？


- 无线通信：信号会被噪声和干扰所破坏。
- 数据存储：硬盘、内存和云节点可能出错。
- 二维码和条形码：部分符号被损坏后仍可解码。
- 深空通信：重传不可能。

核心问题

如何在不可靠的介质上实现可靠通信？

通信系统

- 现代通信系统



- 信源 → 编码器 → 信道 → 译码器 → 用户

信源编码 vs. 信道编码

信源编码

- 目标：压缩
- 场景：无噪表示
- 基本量：
熵 (Entropy)

信道编码

- 目标：可靠性
- 场景：有噪传输
- 基本量：
容量 (Capacity)

两种视角

信息论的问题：

- 极限压缩率是多少？
- 极限通信速率是多少？

编码理论的问题：

- 如何显式地构造好码？
- 如何高效地译码？

Shannon 的里程碑成果

- 信源编码定理：熵给出了极限压缩率。
- 信道编码定理：若传输速率 $R < C$ ，则存在译码错误概率任意小的编码方案。

但 Shannon 定理是存在性的

它告诉我们好码存在，但没有直接告诉我们如何去构造或译码。

本课程

我们主要研究如何构造码、分析其参数并高效译码。

编码理论的历史

- C. E. Shannon (香农, 1948 年):
《A Mathematical Theory of Communication》
- R. W. Hamming (汉明, 1950 年):
《Error Detecting and Error Correcting Codes》: 代数编码理论的开始
 - 第一个纠错码: $[7, 4, 3]$
 - Association for Computing Machinery; ACM (美国计算机协会)

编码理论的历史

- Reed, Muller (1954): **Reed-Muller 码**
- Bose and Ray-Chaudhuri (1960) and Hocquenghem (1959): **BCH 码 (循环码)**
- Reed, Solomon (1960): **Reed-Solomon 码 (最重要的码)**
- 卷积码 (**Convolutional codes**): Viterbi 算法 (1967)
- Goppa 码 (1970), RAID (磁盘阵列, 1980s), LDPC 码, Turbo 码, Polar 码
- 存储编码: Regenerating Codes (再生码), Locally Repairable Codes (局部修复码), Maximal Repairable Codes, ...

一个小例子: YES or NO?

假设我们只想发送两条消息:

YES and NO.

一种朴素的编码是

$\text{YES} \mapsto 1, \quad \text{NO} \mapsto 0.$

- 如果有一个比特发生翻转, 我们甚至无法检测到错误。

一个小例子: YES or NO?

另一种编码是

$\text{YES} \mapsto 11, \quad \text{NO} \mapsto 00.$

- 一个错误可以被检测到，但不一定能被纠正。

一个小例子: YES or NO?

一种可靠的编码是

YES $\mapsto$ 111, NO $\mapsto$ 000.

- 一个错误可以通过多数投票被纠正!

启示

通过添加冗余来实现可靠通信。

- 更多冗余通常意味着更强的保护能力。
- 但更多冗余也意味着更低的传输速率。

基本问题

纠正给定数量的错误需要多少冗余？

- 编码理论 (纠错码理论) 的主要目标
 - 冗余与纠错能力的**权衡**
 - **构造**达到该权衡的最优码
 - 高效的**编码和译码算法**

基本概念

Definition (码, 码字)

- 字母表 (**Alphabet**): 非空有限集 Σ ; $|\Sigma| = q$ (例如 $\Sigma = \{0, 1\}$)
 - $\Sigma^n = \{(x_1, x_2, \dots, x_n) : x_i \in \Sigma\}$
 - 一个长度为 n 、字母表为 Σ 的码 (**code**) $\mathcal{C}$ 是 Σ^n 的一个子集。
 - $\mathcal{C}$ 的一个元素 $c = (c_1, c_2, \dots, c_n)$ 称为一个码字 (**codeword**)。
-
- 我们也可以将 $v = (v_1, v_2, \dots, v_n) \in \Sigma^n$ 看作
 - 一个向量 $(v_1, v_2, \dots, v_n)$
 - 一个序列 $v_1, v_2, \dots, v_n$
 - 一个函数 $f: [n] \rightarrow \Sigma$, 使得 $f(i) = v_i$ 。

- 给定码 $\mathcal{C} \subseteq \Sigma^n$, $|\mathcal{C}| = M$, 我们将 $\mathcal{C}$ 看作一个映射 (编码规则):

$$\mathcal{C} : [M] \longrightarrow \Sigma^n$$

Definition (维数, 码率)

- $\mathcal{C}$ 的维数定义为

$$k := \log_q |\mathcal{C}|.$$

- 维数为 k 、分组长度为 n 的码的码率为

$$R := \frac{k}{n}.$$

两个基本例子

例 (重复码, Repetition code)

设 $\Sigma = \{0, 1\}$, 定义

$$C_{3,\text{rep}}(x) = (x, x, x).$$

则 $n = 3$, $|C_{3,\text{rep}}| = 2$, $R = 1/3$ 。

例 (奇偶校验码, Parity code)

定义

$$C_{\oplus}(x_1, x_2, x_3, x_4) = (x_1, x_2, x_3, x_4, x_1 \oplus x_2 \oplus x_3 \oplus x_4).$$

则 $n = 5$, $|C_{\oplus}| = 2^4$, $R = 4/5$ 。

Definition (编码函数, 编码规则)

- 编码函数: 设 $C \subseteq \Sigma^n$,

$$E: [C] \longrightarrow \Sigma^n.$$

Definition (译码函数, 译码规则)

- 译码函数:

$$D: \Sigma^n \longrightarrow [C]$$

- 编码器添加冗余。
- 译码器试图从可能被损坏的接收字中恢复原始消息。

Hamming 距离与错误

Definition (Hamming 距离, 汉明距离)

给定两个向量 $\mathbf{u}, \mathbf{v} \in \Sigma^n$, $\mathbf{u}$ 与 $\mathbf{v}$ 之间的 Hamming 距离记为 $\Delta(\mathbf{u}, \mathbf{v})$ (或 $d(\mathbf{u}, \mathbf{v})$), 定义为 $\mathbf{u}$ 与 $\mathbf{v}$ 不同的坐标个数, 即

$$\Delta(\mathbf{u}, \mathbf{v}) = |\{1 \leq i \leq n : u_i \neq v_i\}|.$$

Example

$\mathbf{u} = 00000$, $\mathbf{v} = 10001$, 则 $\Delta(\mathbf{u}, \mathbf{v}) = 2$ 。

- 当发送 $\mathbf{u}$ 接收到 $\mathbf{v}$ 时, $\Delta(\mathbf{u}, \mathbf{v})$ 就是错误的个数。


信道

Definition (t -错误信道, t -Error Channel)

字母表 Σ 上的 n -符号 t -错误信道是一个函数 $Ch: \Sigma^n \rightarrow \Sigma^n$, 满足对所有 $v \in \Sigma^n$, $\Delta(v, Ch(v)) \leq t$ 。

Definition (t -纠错码, t -Error-Correcting Code)

设 $C \subseteq \Sigma^n$ 。若存在译码函数 D 使得对每条消息 $m \in [C]$ 和每个 t -错误信道 Ch , 都有 $D(Ch(E(m))) = m$, 则称 C 是 t -纠错码。



Definition (t -检错码, t -Error-Detecting Code)

设 $\mathcal{C} \subseteq \Sigma^n$ 。若存在一个检测过程 D 使得对每条消息 $\mathbf{m} \in [\mathcal{C}]$ 以及所有满足 $\Delta(E(\mathbf{m}), \mathbf{r}) \leq t$ 的接收向量 $\mathbf{r} \in \Sigma^n$, D 在 $\mathbf{r} = E(\mathbf{m})$ 时输出 1, 否则输出 0, 则称 $\mathcal{C}$ 是 t -检错码。

- 每一个 t -纠错码自动也是 t -检错码。

Definition (t -擦除信道, t -Erasure Channel)

字母表 Σ 上的 n -符号 t -擦除信道是一个函数 $Ch: \Sigma^n \rightarrow (\Sigma \cup \{?\})^n$, 满足对所有 $\mathbf{v} \in \Sigma^n$, $\Delta(\mathbf{v}, Ch(\mathbf{v})) \leq t$, 且对每个 $i \in [n]$, 若 $\mathbf{v}_i \neq Ch(\mathbf{v})_i$, 则 $Ch(\mathbf{v})_i = ?$ 。

Definition (t -纠删码, t -Erasure Correcting Code)

设 $C \subseteq \Sigma^n$ 是一个码, $t \geq 1$ 是整数。若存在译码函数 D 使得对每条消息 $\mathbf{m} \in [C]$ 和每个 t -擦除信道 Ch , 都有 $D(Ch(E(\mathbf{m}))) = \mathbf{m}$, 则称 C 是 t -纠删码。

回顾

- 码
- 错误
- Hamming 距离
- 信道
- 纠错码
- 检错码

Proposition

- 重复码: $\Sigma = \{0, 1\}$,

$$C_{3,\text{rep}}(x, y) = (x, x, x, y, y, y)$$

3-重复码 $C_{3,\text{rep}}$ 是 1-纠错码。

证明.

每个信息比特被重复三次。如果一个长度为 3 的块中至多发生一个错误, 则该块中至少有两个符号仍然正确。因此多数投票可以唯一地恢复原始比特。 $\square$

Proposition

- 奇偶校验码: $\Sigma = \{0, 1\}$,

$$C_{\oplus}(x_1, x_2, x_3, x_4) = (x_1, x_2, x_3, x_4, x_1 \oplus x_2 \oplus x_3 \oplus x_4)$$

奇偶校验码 $C_{\oplus}$ 是 1-检错码, 但不是 1-纠错码。

证明.

一个比特翻转会改变奇偶性, 因此总能被检测到。然而纠错失败: 接收字 00001 与 00000 和 00011 的距离都是 1。 $\square$

Hamming 模型 vs. Shannon 模型


- **Hamming** 的最坏情况模型：我们只知道错误数量的一个上界。
- **Shannon** 的概率模型：我们知道噪声是如何以统计方式产生的。

两个互补的目标


最坏情况保证在数学上是稳健的，而概率模型给出了信道容量和最优译码规则。

二元对称信道

- 二元对称信道 (BSC, 二元对称信道) $BSC(p)$ 以概率 p 独立地翻转每个比特。
- 交叉概率满足 $0 \leq p \leq 1$ 。



- 二元对称信道 (BSC, 二元对称信道), 交叉概率 $0 \leq p \leq 1$ 。在此模型中, 当 (二元) 码字通过信道传输时, 每个比特以概率 p 独立地发生翻转。



译码准则

- 最大后验概率 (MAP) 译码 (最大后验概率译码, 最优译码)
 - $D_{MAP}(\mathbf{r}) = \arg \max_{c \in \mathcal{C}} P(c \text{ sent} \mid \mathbf{r} \text{ received})$
- 最大似然 (MLD) 译码 (最大似然译码)
 - $D_{MLD}(\mathbf{r}) = \arg \max_{c \in \mathcal{C}} P(\mathbf{r} \text{ received} \mid c \text{ sent})$
- MAP 与 MLD 的关系?
 - $P(c|\mathbf{r}) \cdot P(\mathbf{r}) = P(\mathbf{r}|c) \cdot P(c)$
 - 若所有码字是等概率的, 则 MAP 译码和 MLD 是相同的。

- 最近邻/最小距离译码（最近邻译码，最小距离译码）
 - $D(\mathbf{r}) = \arg \min_{\mathbf{c} \in \mathcal{C}} \Delta(\mathbf{c}, \mathbf{r})$

Theorem (BSC 上的 MLD 译码)

对于交叉概率 $p < 1/2$ 的 BSC，最大似然译码规则与最近邻译码规则相同。

证明.

对于固定的接收字 $\mathbf{r}$ 和码字 $\mathbf{c}$,

$$P(\mathbf{r} | \mathbf{c}) = p^{\Delta(\mathbf{c}, \mathbf{r})} (1 - p)^{n - \Delta(\mathbf{c}, \mathbf{r})}.$$

因为 $p < 1/2$ ，因子 $p/(1 - p)$ 小于 1，所以似然函数随 $\Delta(\mathbf{c}, \mathbf{r})$ 的增大而严格减小。因此最大化似然等价于最小化 Hamming 距离。 $\square$

译码错误概率

- 译码器 $\mathcal{D}$ 的译码错误概率 P_{err} 定义为

$$P_{\text{err}} = \max_{c \in \mathcal{C}} P_{\text{err}}(c),$$

其中

$$P_{\text{err}}(c) = \sum_{y: \mathcal{D}(y) \neq c} \text{Prob}\{\mathbf{y} \text{ received} \mid c \text{ transmitted}\}.$$

- $P_{\text{err}}(c)$ 是在给定发送 c 的条件下，码字 c 被错误译码的概率。

Example

设 C 是重复码, S 为交叉概率为 p 的 BSC。 P_{err} 等于发生两个或更多错误的概率:

$$\begin{aligned} P_{\text{err}} &= P_{\text{err}}(000) = P_{\text{err}}(111) = \binom{3}{2} p^2 (1-p) + \binom{3}{3} p^3 \\ &= 3p^2 - 3p^3 + p^3 \\ &= p(2p-1)(1-p) + p \end{aligned}$$

- 当 $p < 1/2$ 时, P_{err} 小于 p 。
- 但代价体现在码率上: 每个信息比特需要传输三个比特。

纠错能力与 Hamming 距离

- 检错码与纠错码的新刻画

Proposition (t -检错码)

- C 是 t -检错码当且仅当对任意 $c \in C$, 若 $0 < \Delta(c, x) \leq t$, 则 $x \notin C$ 。

Proposition (t -纠错码)

- C 是 t -纠错码当且仅当对任意 $c_1, c_2 \in C$, 若 $\Delta(c_1, x) \leq t$ 且 $d(c_2, x) \leq t$, 则 $c_1 = c_2$ 。

Example

- 二元码 $C = \{00000, 00111, 11111\}$ 是 1-检错码。
- 二元码 $C = \{000, 111\}$ 是 1-纠错码。

Definition (码的极小距离)

码 C 的极小距离 (或简称距离), 记为 $\Delta(C)$ 或 Δ , 定义为

$$\Delta(C) = \min_{c_1 \neq c_2 \in C} \Delta(c_1, c_2)$$

Example

$C = \{(0, 0, 0, 1, 0), (1, 0, 1, 0, 0), (1, 1, 0, 0, 0), (1, 0, 0, 0, 1)\}$
 $\Delta(C) = ?$

Example

- $\Delta(C_{\oplus}) = 2$
- $\Delta(C_{3,\text{rep}}) = 3$

Proposition (Hamming 距离是度量)

- ① $\Delta(u, v) \geq 0$ (非负性)
- ② $\Delta(u, v) = 0$ 当且仅当 $u = v$ (正则性)
- ③ $\Delta(u, v) = \Delta(v, u)$ (对称性)
- ④ $\Delta(u, v) \leq \Delta(u, w) + \Delta(w, v)$ (三角不等式)

思路.

前三个性质是显然的。对于三角不等式， u 与 v 不同的每个坐标，必然在 (u, w) 或 (w, v) 中至少一个对中不同。 $\square$

Theorem (极小距离与检错性能)

码 C 是 t -检错码当且仅当 $\Delta(C) \geq t+1$ ；换言之，极小距离为 d 的码是 $(d-1)$ -检错码。

证明.

“ $\Rightarrow$ ”:

- 反证法：假设 $\Delta(C) \leq t$ ，则 $\exists c_1 \neq c_2 \in C$, s.t. $0 < \Delta(c_1, c_2) \leq t$ 。
矛盾！

“ $\Leftarrow$ ”:

- 假设 $c \in C$ 且 $0 < \Delta(c, x) \leq t$ 。
- 因为 $\Delta(C) \geq t+1$ ，于是 $x \notin C$ 。

□

Theorem (极小距离与纠错性能)

码 C 是 t -纠错码当且仅当 $\Delta(C) \geq 2t + 1$ ；换言之，极小距离为 d 的码是 $\lfloor \frac{d-1}{2} \rfloor$ -纠错码。

证明.

“ $\implies$ ”:

- 反证法：假设 $\Delta(C) \leq 2t$ ，则 $\exists c_1 \neq c_2 \in C$, s.t. $\Delta(c_1, c_2) \leq 2t$.
- 于是 $\exists x$ s.t., $\Delta(c_1, x) \leq t$ 并且 $\Delta(x, c_2) \leq t$ (Why?)

“ $\impliedby$ ”:

- 假设 $c_1, c_2 \in C$, $\Delta(c_1, x) \leq t$ 且 $\Delta(c_2, x) \leq t$,
- 于是 $\Delta(c_1, c_2) \leq \Delta(c_1, x) + \Delta(c_2, x) \leq 2t$.
- 因为 $\Delta(C) \geq 2t + 1$, 故 $c_1 = c_2$.

□

统一图景

若码的极小距离为 d ，则它可以：

- 检测至多 $d - 1$ 个错误，
- 纠正至多 $\lfloor \frac{d-1}{2} \rfloor$ 个错误，
- 纠正至多 $d - 1$ 个擦除。

极小距离

极小距离是决定码的纠错控制能力的最重要的单一参数。

Definition

维数为 k 、距离为 d 的码 $C \subseteq \Sigma^n$ 称为 $(n, k, d)_\Sigma$ 码。也记为 $(n, k, d)_{|\Sigma|}$ 码。

- 固定 n ，增大 k 通常会减小 d 。
- 增大 d 通常需要更多冗余，从而降低码率。

问题

距离为 d 的码可以达到的最大码率 R 是多少？

问题

能否有距离为 3 且码率严格大于 $1/3$ 的二元码？

Hamming 码, 汉明码

- $\Sigma = \{0, 1\}$

$$C_H(x_1, x_2, x_3, x_4) = (x_1, x_2, x_3, x_4, x_2 \oplus x_3 \oplus x_4, x_1 \oplus x_3 \oplus x_4, x_1 \oplus x_2 \oplus x_4)$$

- $q = 2, k = 4, n = 7, R = 4/7$

对前述问题的回答

是的。Hamming 码的距离为 3 且码率 $4/7 > 1/3$ 。

Definition (Hamming 重量, 汉明重量)

设 $q \geq 2$ 。给定任意向量 $\mathbf{v} \in \{0, 1, 2, \dots, q-1\}^n$, 其 Hamming 重量记为 $wt(\mathbf{v})$, 定义为 $\mathbf{v}$ 中非零符号的个数。

- $wt(\mathbf{v}) = \Delta(\mathbf{v}, \mathbf{0})$

Example

$\mathbf{v} = 01203400$, 则 $wt(\mathbf{v}) = 4$ 。

- $\Delta(\mathbf{u}, \mathbf{v}) = wt(\mathbf{u} - \mathbf{v})$

Proposition (Hamming 码的极小距离)

$$\Delta(C_H) = 3.$$

- 生成矩阵:

$$G_H = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 1 & 1 \\ 0 & 1 & 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 & 1 & 1 & 1 \end{pmatrix}.$$

- $C_H = \{(x_1, x_2, x_3, x_4) \cdot G_H : (x_1, x_2, x_3, x_4) \in \{0, 1\}^4\}$

Definition (二元线性码)

二元线性码:

$$C = \{\mathbf{x} \cdot G : \mathbf{x} \in \{0, 1\}^k\}$$

Lemma

对任意二元线性码 C 和任意两条消息 x, y ,

$$C(x) + C(y) = C(x + y)$$

Proposition (线性码的极小距离与极小重量)

对任意二元线性码 C ,

$$\Delta(C) = \min_{c \neq \mathbf{0} \in C} wt(c).$$

为什么这个公式成立

对任意两个码字 $\mathbf{c}_1, \mathbf{c}_2 \in C$,

$$\Delta(\mathbf{c}_1, \mathbf{c}_2) = wt(\mathbf{c}_1 - \mathbf{c}_2).$$

因为 C 是线性的, $\mathbf{c}_1 - \mathbf{c}_2 \in C$ 。因此两个码字之间的距离恰好是另一个码字的重量。对所有不同对取最小值与对所有非零码字取最小重量是一样的。 $\square$

Proposition (Hamming 码的极小距离)

$$\Delta(C_H) = 3.$$

证明.

- 设 $\mathbf{c} = (x_1, x_2, x_3, x_4, x_2 \oplus x_3 \oplus x_4, x_1 \oplus x_3 \oplus x_4, x_1 \oplus x_2 \oplus x_4) \neq 0 \in C_H$, 则 x_1, x_2, x_3, x_4 不全为 0
- 最多一个为 0: $wt(\mathbf{c}) \geq 4$
- 恰有两个 0: 则 $x_2 \oplus x_3 \oplus x_4, x_1 \oplus x_3 \oplus x_4, x_1 \oplus x_2 \oplus x_4$ 中至少一个为 1。
- 恰有三个 0: 1) $x_4 = 1$; 2) $x_4 = 0$ □

Hamming 界, 汉明界

Definition (Hamming 球, 汉明球)

对任意向量 $\mathbf{x} \in [q]^n$,

$$B_q(\mathbf{x}, r) = \{\mathbf{y} \in [q]^n : \Delta(\mathbf{x}, \mathbf{y}) \leq r\}.$$

Example

$B_2(\mathbf{0}, 1) = \{(0, 0), (0, 1), (1, 0)\}$ 在 $\{0, 1\}^2$ 中;

$B_2(\mathbf{1}, 1) = \{(1, 1), (1, 0), (0, 1)\}$ 在 $\{0, 1\}^2$ 中

- $|B_q(\mathbf{x}, 1)| = ?$

Theorem (Hamming 界, $d = 3$)

每个分组长度为 n 、维数为 k 、距离 $d = 3$ 的二元码满足

$$k \leq n - \log_2(n + 1).$$

证明.

- 以每个码字 c 为球心, 1 为半径作球 $B_2(c, 1)$ 。
- 这些球两两不交。
- $\sum_{c \in C} |B_2(c, 1)| \leq 2^n$

□

广义 Hamming 界

Proposition (Hamming 球的大小)

$$|B(\mathbf{x}, r)| = \sum_{i=0}^r \binom{n}{i} (q-1)^i.$$

Proof:

Theorem (广义 Hamming 界)

对任意 $(n, k, d)_q$ 码,

$$k \leq n - \log_q \left(\sum_{i=0}^{\lfloor \frac{d-1}{2} \rfloor} \binom{n}{i} (q-1)^i \right).$$

Proof:

- 特别地，任意距离为 d 的码的码率 R 至多为

$$1 - \frac{\log_q \left(\sum_{i=0}^{\lfloor \frac{d-1}{2} \rfloor} \binom{n}{i} (q-1)^i \right)}{n}.$$

Definition

达到 Hamming 界的码称为完美码 (**perfect codes**)。

问题

除了 Hamming 码以外，还有其他完美（二元）码吗？