

信息论与编码

课堂笔记

目录

第 1 章 熵、相对熵和互信息	3
1.1 熵的定义	3
1.1.1 换底公式	3
1.1.2 二元熵函数	4
1.2 联合熵与条件熵	4
1.3 链式法则	5
1.4 互信息	5
1.4.1 条件互信息	6
1.4.2 互信息的链式法则	7
1.5 相对熵	7
1.6 凸性与 Jensen 不等式	8
1.6.1 证明（离散情形）	8
1.7 信息不等式	9
1.8 熵的性质总结	9
1.8.1 互信息非负性	9
1.8.2 熵的上界	10
1.8.3 条件不减少熵	10
1.8.4 熵的独立界	10
1.8.5 熵的上凸性	11
1.9 数据处理不等式	12

目录	2
1.9.1 马尔可夫链	12
1.9.2 数据处理不等式	13
1.10 熵的组合法则	13
1.11 Fano 不等式	14
1.12 熵与组合计数	15
第 2 章 典型集与 AEP	16
2.1 AEP 性质	16
2.2 典型集	17
2.3 AEP 的推论：数据压缩	18
第 3 章 信源编码	18
3.1 编码定义	18
3.2 最优码长	19
3.3 Kraft 不等式	19
3.4 Shannon 码	20
3.5 Huffman 码	20
3.6 Shannon-Fano-Elias 编码	21

第 1 章 熵、相对熵和互信息

1.1 熵的定义

定义 熵

随机变量 X 的熵 $H(X)$ ，定义为传输 X 所需比特数的期望。

例 1.1.1. 设 $X \sim P_X$ ，Alice 知道 X 的值，通过信道将其传送给 Bob：

$$\text{Alice} \xrightarrow{X=x} \text{Bob}$$

例 1.1.2. 若 $P(X=0)=1$ ，则 Alice 不需要传输任何信息 (0 bit)。

例 1.1.3. 若 P_X 为 $\{0,1\}^n$ 上的均匀分布，则 Alice 需要发送 n bit 来传输信息。

例 1.1.4. X 以 $\frac{1}{2}$ 的概率取 $\{0\}^n$ (case 1)，以 $\frac{1}{2}$ 的概率在 $\{0,1\}^n$ 上均匀分布 (case 2)。Alice 先用 1 bit 说明属于哪种情形：

- case 1: $X = \{0\}^n$ ，额外编码 0 位，概率 $P = \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2^n}$ 。
- case 2: $X \neq \{0\}^n$ ，编码 $1a_1a_2 \cdots a_n$ ，概率 $P = \frac{1}{2} \cdot \frac{1}{2^n}$ 。

总期望比特数约为

$$E \approx \frac{n}{2} + 1.$$

定义 熵的公式

设随机变量 X 的字母表为 $\mathcal{X}$ ，概率分布为 $p(x)$ ，则

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log p(x) = \sum_{x \in \mathcal{X}} p(x) \log \frac{1}{p(x)}.$$

约定：若 $p(x)=0$ ，令 $0 \log 0 = 0$ 。

1.1.1 换底公式

以 b 为底的熵定义为

$$H_b(X) = - \sum_{x \in \mathcal{X}} p(x) \log_b p(x).$$

与以 2 为底的熵之间有换底关系：

$$H_b(X) = (\log_b 2) H(X).$$

引理 熵的非负性

$$H(X) \geq 0, \quad H(X) = 0 \iff X \text{ 为确定变量 (退化分布) }.$$

1.1.2 二元熵函数


例 1.1.5. 设

$$X = \begin{cases} 1 & \text{以概率 } p, \\ 0 & \text{以概率 } 1 - p, \end{cases}$$

则

$$H(X) = -p \log p - (1 - p) \log(1 - p) \triangleq H(p).$$

当 $p = \frac{1}{2}$ 时, $H(p)$ 取最大值 1。



1.2 联合熵与条件熵

定义 联合熵

设 $(X, Y) \sim p(x, y)$, 则联合熵定义为

$$H(X, Y) = - \sum_{(x, y) \in \mathcal{X} \times \mathcal{Y}} p(x, y) \log p(x, y).$$

定义 条件熵

$$H(X | Y) = \sum_{y \in \mathcal{Y}} p(y) H(X | Y = y) = \sum_{y \in \mathcal{Y}} p(y) \left[- \sum_{x \in \mathcal{X}} p(x | y) \log p(x | y) \right]$$

$$= - \sum_{\substack{(x,y) \\ \in \mathcal{X} \times \mathcal{Y}}} p(x,y) \log p(x | y) = - \mathbb{E}_p[\log p(X | Y)].$$

1.3 链式法则

定理 链式法则

$$H(X, Y) = H(X) + H(Y | X) = H(Y) + H(X | Y).$$

证明：(略)

推广：

$$H(X, Y | Z) = H(X | Z) + H(Y | X, Z).$$

推导：

$$\begin{aligned} H(X, Y | Z) &= \sum_{z \in \mathcal{Z}} p(z) H(X, Y | Z = z) \\ &= \sum_{z \in \mathcal{Z}} p(z) H(X | Z = z) + \sum_{z \in \mathcal{Z}} p(z) H(Y | X, Z = z). \end{aligned}$$

例 1.3.1. 设随机变量 X, Y 的联合分布满足：


$$\begin{aligned} H(Y) &= H\left(\frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4}\right) = 2 \text{ bits}, \\ H(X) &= H\left(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}\right) = \frac{7}{4} \text{ bits}, \\ H(X | Y) &= \sum_{y \in \mathcal{Y}} p(y) H(X | Y = y). \end{aligned}$$

1.4 互信息

定义 互信息

$$I(X; Y) = H(X) - H(X | Y) = H(Y) - H(Y | X).$$

各信息量之间的关系如下图所示：



命题 互信息的等价表示

设 $(X, Y) \sim p(x, y)$, 边缘分布 $X \sim p(x)$, $Y \sim p(y)$, 则


$$\begin{aligned} I(X; Y) &= H(X) - H(X | Y) \\ &= H(Y) - H(Y | X) \\ &= D(p(x, y) \parallel p(x)p(y)). \end{aligned}$$

1.4.1 条件互信息

定义 条件互信息

$$I(X; Y | Z) := H(X | Z) - H(X | Y, Z).$$

注：三元互信息 $I(X; Y; Z)$ 可以为负（不同于二元情形）。如图所示，设 $X, Y, Z \in \{0, 1\}$, X 与 Y 独立且均匀分布, $Z = X \oplus Y$ 。则在 Venn 图中每个非空区域均对应 1 bit, 而三重交集区域计数为 -1 , 即 $I(X; Y; Z) = -1 < 0$ 。



联合分布为

X	Y	Z	Pr
0	0	0	1/4
0	1	1	1/4
1	0	1	1/4
1	1	0	1/4

注意任意两变量的边缘分布相同: $P_{XY} = (\frac{1}{4}, \frac{1}{4}; \frac{1}{4}, \frac{1}{4}) = P_{XZ} = P_{YZ}$ 。

以条件互信息为例验算:

$$I(X; Y | Z) = H(X | Z) - H(X | Y, Z) = H(X) - 0 = 1 \text{ bit}.$$

1.4.2 互信息的链式法则

回顾熵的链式法则:

$$H(X_1^n) = \sum_{i=1}^n H(X_i | X_1^{i-1}).$$

类似地, 互信息也有链式展开:

$$I(X_1^n; Y) = \sum_{i=1}^n I(X_i; Y | X_1^{i-1}).$$

例 1.4.1. 当 $n = 2$ 时,

$$I(X_1, X_2; Y) = I(X_1; Y) + I(X_2; Y | X_1).$$

1.5 相对熵

定义 相对熵 / K-L 散度

设 $p(x), q(x)$ 为字母表 $\mathcal{X}$ 上的两个概率分布, 则**相对熵**定义为

$$D(p \| q) = \sum_{x \in \mathcal{X}} p(x) \log \frac{p(x)}{q(x)}.$$

约定:

$$0 \log \frac{0}{q(x)} = 0, \quad p \log \frac{p}{0} = +\infty \quad (p > 0).$$

例 1.5.1. 设 $\mathcal{X} = \{0, 1\}$,

$$p = \begin{cases} 0 & \text{以概率 } 1-r, \\ 1 & \text{以概率 } r, \end{cases} \quad q = \begin{cases} 0 & \text{以概率 } 1-s, \\ 1 & \text{以概率 } s. \end{cases}$$

则

$$D(p \parallel q) = (1-r) \log \frac{1-r}{1-s} + r \log \frac{r}{s},$$

$$D(q \parallel p) = (1-s) \log \frac{1-s}{1-r} + s \log \frac{s}{r}.$$

注意：一般地， $D(p \parallel q) \neq D(q \parallel p)$ (K-L 散度不具有对称性)。

1.6 凸性与 Jensen 不等式

定理 Jensen 不等式


设函数 f 定义在区间 (a, b) 上。若对所有 $x_1, x_2 \in (a, b)$ 及 $0 \leq \lambda \leq 1$, 均有

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2),$$

则称 $f(x)$ 为**下凸函数** (凸函数, convex function)。

对下凸函数 f 和随机变量 X , 有

$$\mathbb{E}f(X) \geq f(\mathbb{E}X).$$



1.6.1 证明 (离散情形)

设随机变量 X 以概率 $p_1, p_2, \dots, p_k$ 分别取值 $x_1, x_2, \dots, x_k$, 对下凸函数 f , 需证

$$\mathbb{E}f(X) = \sum_{i=1}^k p_i f(x_i) \geq f\left(\sum_{i=1}^k p_i x_i\right) = f(\mathbb{E}X).$$

当 $k = 2$ 时：取 $p_1 = \lambda$, $p_2 = 1 - \lambda$, 即凸函数的定义：

$$\lambda f(x_1) + (1 - \lambda)f(x_2) \geq f(\lambda x_1 + (1 - \lambda)x_2).$$

当 $k = 3$ 时：令 $p_3 = 1 - p_1 - p_2$,

$$p_1 f(x_1) + p_2 f(x_2) + (1 - p_1 - p_2)f(x_3) \geq f(p_1 x_1 + p_2 x_2 + (1 - p_1 - p_2)x_3).$$

一般情形可用数学归纳法类似得到。 $\square$

1.7 信息不等式

定理 信息不等式

- (1) $D(p \parallel q) \geq 0$;
- (2) 等号成立 $\iff p = q$ 。

证明：注意 $\log$ 是上凸函数，对上凸函数有 $\mathbb{E}f(X) \leq f(\mathbb{E}X)$ ，故令 $X \sim p(x)$ 并令 $f = \log$ ：

$$\begin{aligned} D(p \parallel q) &= \sum_{x \in \mathcal{X}} p(x) \log \frac{p(x)}{q(x)} = - \sum_{x \in \mathcal{X}} p(x) \log \frac{q(x)}{p(x)} \\ &= -\mathbb{E} \left[\log \frac{q(X)}{p(X)} \right] \geq -\log \mathbb{E} \left[\frac{q(X)}{p(X)} \right] \\ &= -\log \left(\sum_{x \in \mathcal{X}} p(x) \cdot \frac{q(x)}{p(x)} \right) = -\log \left(\sum_{x \in \mathcal{X}} q(x) \right) = -\log 1 = 0. \end{aligned}$$

等号条件：等号成立 $\iff X$ 为确定值 $\iff \frac{q(x)}{p(x)} = \gamma$ 对所有 $x \in \mathcal{X}$ 成立。由归一化条件 $\sum q(x) = 1$ 、 $\sum p(x) = 1$ 可得 $\gamma = 1$ ，即 $p = q$ 。 $\square$

1.8 熵的性质总结

1.8.1 互信息非负性

命题 互信息非负性

- (1) $I(X; Y) = D(p(x, y) \parallel p(x)p(y)) \geq 0$;
- (2) 等号成立 $\iff p(x, y) = p(x)p(y)$, $\forall x, y \iff X$ 与 Y 相互独立。

1.8.2 熵的上界

定理 熵的上界

- (1) $H(X) \leq \log |\mathcal{X}|$;
 (2) 等号成立 $\iff X$ 服从均匀分布。

证明： 设 X 以概率 $p_1, \dots, p_n$ 取 n 个值，令 $f = \log$ (上凸)，构造随机变量 $X' = \frac{1}{p_i}$ 以概率 p_i 取值，则

$$H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = \mathbb{E}[\log X'] \leq \log \mathbb{E}[X'] = \log \left(\sum_{i=1}^n p_i \cdot \frac{1}{p_i} \right) = \log n = \log |\mathcal{X}|.$$

等号成立 $\iff X'$ 为确定值 $\iff p_1 = \dots = p_n = \frac{1}{n}$ ，即均匀分布。 $\square$

1.8.3 条件不减少熵

定理 条件不减少熵

$$H(X | Y) \leq H(X).$$

证明： 由互信息非负性，

$$I(X; Y) = H(X) - H(X | Y) \geq 0,$$

故 $H(X | Y) \leq H(X)$ 。 $\square$

例 1.8.1. 设 (X, Y) 的联合分布如下：

$Y \setminus X$	1	2	$p(y)$
1	0	$\frac{3}{4}$	$\frac{3}{4}$
2	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{4}$
$p(x)$	$\frac{1}{8}$	$\frac{7}{8}$	

则

$$H(X) = H\left(\frac{1}{8}, \frac{7}{8}\right) \approx 0.544 \text{ bits},$$

$$H(X | Y = 1) = 0, \quad H(X | Y = 2) = 1,$$

$$H(X | Y) = \frac{3}{4} \cdot 0 + \frac{1}{4} \cdot 1 = 0.25 \text{ bits} \leq H(X).$$

1.8.4 熵的独立界

命题 熵的独立界

$$H(X_1^n) \leq \sum_{i=1}^n H(X_i).$$

等号成立当且仅当 $X_1, \dots, X_n$ 相互独立。

证明： 由链式法则展开，再利用条件不减少熵：

$$H(X_1^n) = \sum_{i=1}^n H(X_i | X_1^{i-1}) \leq \sum_{i=1}^n H(X_i).$$

特别地，

$$n = 2: \quad H(X_1, X_2) = H(X_1) + H(X_2 | X_1),$$

$$\begin{aligned} n = 3: \quad H(X_1, X_2, X_3) &= H(X_1) + H(X_2 | X_1) + H(X_3 | X_1, X_2) \\ &= H(X_1, X_2) + H(X_3 | X_1, X_2). \quad \square \end{aligned}$$

1.8.5 熵的上凸性**定理 熵是分布的上凸函数**

H 是关于概率分布 P_X 的**上凸** (concave) 函数，即

$$H\left(\sum_{x \in \mathcal{X}} \lambda_j P_j\right) \geq \sum_j \lambda_j H(P_j), \quad \lambda_j \geq 0, \sum_j \lambda_j = 1.$$

注记： 由 $H(Y) \geq H(Y | X)$ 可以直观理解此性质。令

$$P_Y(\cdot) = \sum_{x \in \mathcal{X}} P_X(x) P_{Y|X}(\cdot | x),$$


则

$$\begin{aligned} H(Y) &= H\left(\sum_{x \in \mathcal{X}} P_X(x) P_{Y|X}(\cdot | x)\right), \\ H(Y | X) &= \sum_{x \in \mathcal{X}} P_X(x) H(P_{Y|X}(\cdot | x)). \end{aligned}$$

由 $H(Y) \geq H(Y | X)$ 即得

$$H\left(\sum_{x \in \mathcal{X}} P_X(x) P_{Y|X}(\cdot | x)\right) \geq \sum_{x \in \mathcal{X}} P_X(x) H(P_{Y|X}(\cdot | x)),$$

从而 H 是关于 P_X 的上凸函数。



即对二元情形有

$$H(\lambda p_1 + (1 - \lambda)p_2, 1 - \lambda p_1 - (1 - \lambda)p_2) \geq \lambda H(p_1, 1 - p_1) + (1 - \lambda) H(p_2, 1 - p_2).$$

1.9 数据处理不等式

1.9.1 马尔可夫链

定义 马尔可夫链

称 $X \rightarrow Y \rightarrow Z$ 构成马尔可夫链，若

$$p(x, y, z) = p(x) p(y | x) p(z | y),$$

等价地， $p(x, y, z) = p(x) p(y | x) p(z | y, x)$ 中 $p(z | y, x) = p(z | y)$ 。

命题 推论

- (1) $X \rightarrow Y \rightarrow Z \iff$ 给定 Y 时， X 与 Z 条件独立，即 $p(x, z | y) = p(x | y) p(z | y)$ 。
- (2) $X \rightarrow Y \rightarrow Z \iff Z \rightarrow Y \rightarrow X$ 。
- (3) 若 $Z = f(Y)$ ，则 $X \rightarrow Y \rightarrow Z$ 。

1.9.2 数据处理不等式

定理 数据处理不等式

若 $X \rightarrow Y \rightarrow Z$ ，则

$$I(X; Y) \geq I(X; Z).$$

证明：对 $I(X; Y, Z)$ 进行两种链式展开：

$$\begin{aligned} I(X; Y, Z) &= I(X; Y) + \underbrace{I(X; Z | Y)}_{=0 \text{ (马尔可夫性)}} \\ &= I(X; Z) + \underbrace{I(X; Y | Z)}_{\geq 0}. \end{aligned}$$

因此 $I(X; Y) = I(X; Z) + I(X; Y | Z) \geq I(X; Z)$ 。 □

特别情形 1：若 $Z = f(Y)$ ，则 $X \rightarrow Y \rightarrow Z$ ，故

$$I(X; Y) \geq I(X; f(Y)).$$

特别情形 2：取 $Y = X$ ， $Z = f(Y) = f(X)$ ，则 $X \rightarrow X \rightarrow f(X)$ ，故

$$I(X; Y) = I(X; X) = H(X) \geq I(X; Z).$$

由于

$$\begin{aligned} I(X; X) &= H(X) - H(X | X) = H(X), \\ I(X; f(X)) &= H(f(X)) - \underbrace{H(f(X) | X)}_{=0} = H(f(X)), \end{aligned}$$

因此

$$\boxed{H(X) \geq H(f(X)).}$$

等号条件： $H(X) = H(f(X)) \Leftrightarrow H(X | f(X)) = 0 \Leftrightarrow f$ 为一一函数（单射）。

这是因为

$$H(X, f(X)) = H(X) + \underbrace{H(f(X) | X)}_{=0} = H(f(X)) + H(X | f(X)),$$

所以 $H(X) - H(f(X)) = H(X | f(X))$ ，等于零当且仅当 f 为一一函数。

1.10 熵的组合法则


命题 熵的组合法则 (Grouping Axiom)

设 $\vec{p} = (p_1, p_2, \dots, p_{m-2}, p_{m-1}, p_m)$, $\vec{q} = (p_1, p_2, \dots, p_{m-2}, p_{m-1} + p_m)$, 则

$$H(\vec{p}) = H(\vec{q}) + (p_{m-1} + p_m) H\left(\frac{p_{m-1}}{p_{m-1} + p_m}, \frac{p_m}{p_{m-1} + p_m}\right).$$

例 1.10.1. 设 $\vec{p} = (\frac{1}{2}, \frac{1}{3}, \frac{1}{6})$, 将后两项合并得 $\vec{q} = (\frac{1}{2}, \frac{1}{2})$, 则

$$H(\frac{1}{2}, \frac{1}{3}, \frac{1}{6}) = H(\frac{1}{2}, \frac{1}{2}) + \frac{1}{2} H(\frac{2}{3}, \frac{1}{3}).$$

**1.11 Fano 不等式****定理 Fano 不等式**

假设 $X \rightarrow Y \rightarrow \hat{X}$ (其中 $\hat{X} = g(Y)$), 记错误概率 $P_e = \Pr(\hat{X} \neq X)$, 则

$$H(X | \hat{X}) \leq h(P_e) + P_e \log(|\mathcal{X}| - 1).$$

进而, 由数据处理不等式 $H(X | Y) \leq H(X | \hat{X})$, 有

$$H(X | Y) \leq h(P_e) + P_e \log(|\mathcal{X}| - 1).$$

证明: 引入误差指示变量

$$E = \begin{cases} 0, & X = \hat{X}, \\ 1, & X \neq \hat{X}. \end{cases}$$

对 $H(X, E | \hat{X})$ 进行两种链式展开。

第一种展开:

$$H(X, E | \hat{X}) = H(X | \hat{X}) + \underbrace{H(E | X, \hat{X})}_{=0},$$

因为给定 X 和 $\hat{X}$ 后, E 是确定的 ($E = \mathbf{1}[X \neq \hat{X}]$)。

第二种展开:

$$H(X, E | \hat{X}) = H(E | \hat{X}) + H(X | E, \hat{X}).$$

对第一项, $H(E | \hat{X}) \leq H(E) = h(P_e)$ 。

对第二项, 按 E 的取值展开:

$$\begin{aligned} H(X | E, \hat{X}) &= \Pr(E=0) \underbrace{H(X | \hat{X}, E=0)}_{=0} + \Pr(E=1) H(X | \hat{X}, E=1) \\ &\leq P_e \cdot \log(|\mathcal{X}| - 1). \end{aligned}$$

其中 $E=0$ 时 $X = \hat{X}$, 故 $H = 0$; $E=1$ 时 $X \neq \hat{X}$, X 最多取 $|\mathcal{X}| - 1$ 个值, 故 $H \leq \log(|\mathcal{X}| - 1)$ 。

综合两种展开,

$$H(X | \hat{X}) = H(E | \hat{X}) + H(X | E, \hat{X}) \leq h(P_e) + P_e \log(|\mathcal{X}| - 1).$$

又因为 $\hat{X} = g(Y)$, $X \rightarrow Y \rightarrow \hat{X}$ 构成马尔可夫链, 由数据处理不等式 $H(X | Y) \leq H(X | \hat{X})$, 故

$$H(X | Y) \leq H(X | \hat{X}) \leq h(P_e) + P_e \log(|\mathcal{X}| - 1). \quad \square$$

1.12 熵与组合计数

考虑长为 N 的 $\{0, 1\}$ 序列, 其中“0”出现概率为 p , “1”出现概率为 $1 - p$ 。

例 1.12.1. $N = 1000$, $p = 0.1$, $1 - p = 0.9$, 则

$$\#\{0^{100}1^{900} \text{ 的排列数}\} = \binom{1000}{100} \approx 2^{1000 \cdot h(0.1)}.$$

Stirling 公式:

$$n! \sim \left(\frac{n}{e}\right)^n \sqrt{2\pi n}.$$

引理 二项系数的渐近界

对所有使 np 为整数的 $0 < p < 1$, $q = 1 - p$, 有

$$\frac{1}{\sqrt{8npq}} \leq \frac{\binom{n}{np}}{2^{nh(p)}} \leq \frac{1}{\sqrt{\pi npq}}.$$

记号: $a_n \doteq b_n$ 表示 $\lim_{n \rightarrow \infty} \frac{1}{n} \log \frac{a_n}{b_n} = 0$ 。

更一般地,考虑字母表 $\{1, 2, \dots, k\}$ 上的长 n 序列,各符号出现概率为 $p_1, p_2, \dots, p_k$, 则

$$\#\{1^{p_1 n} 2^{p_2 n} \dots k^{p_k n} \text{ 的排列数}\} = \binom{n}{p_1 n, p_2 n, \dots, p_k n} = \frac{n!}{(p_1 n)! (p_2 n)! \dots (p_k n)!} \doteq 2^{nH(p_1, \dots, p_k)}.$$

例 1.12.2. 设 $P(x=0) = \frac{1}{3}$, $P(x=1) = \frac{2}{3}$, 当 n 足够大时, $x_1 \dots x_n \sim 0^{n/3} 1^{2n/3}$ 。

$$\#\{0^{n/3} 1^{2n/3} \text{ 的排列数}\} \doteq 2^{nh(1/3)}.$$

每个这样的序列出现概率为

$$\left(\frac{1}{3}\right)^{n/3} \left(\frac{2}{3}\right)^{2n/3} = 2^{-nh(1/3)}.$$

典型集概率 $> 1 - \varepsilon$, 非典型集概率 $< \varepsilon$ 。

第 2 章 典型集与 AEP

2.1 AEP 性质

命题 Markov 不等式

对任意非负随机变量 X 及 $t > 0$,

$$\Pr\{X > t\} \leq \frac{\mathbb{E}X}{t}.$$

命题 Chebyshev 不等式

对任意随机变量 Y , $\mathbb{E}(Y) = \mu < +\infty$, $\text{Var}(Y) = \sigma^2$, $\forall \varepsilon > 0$,

$$\Pr\{|Y - \mu| > \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}.$$

(令 $X = (Y - \mu)^2$ 代入 Markov 不等式即得。)

定理 弱大数定律

设 $Z_1, \dots, Z_n$ 为 i.i.d. 随机变量, $\mathbb{E}(Z_i) = \mu$, $\text{Var}(Z_i) = \sigma^2 < +\infty$, $\bar{Z}_n = \frac{1}{n} \sum_{i=1}^n Z_i$ 为样本均值, 则

$$\Pr\{|\bar{Z}_n - \mu| > \varepsilon\} \leq \frac{\sigma^2}{n\varepsilon^2}.$$

定义 依概率收敛

给定随机变量序列 $X_1, X_2, \dots$, 若 $\forall \varepsilon > 0$,

$$\Pr\{|X_n - x| > \varepsilon\} \rightarrow 0 \quad (n \rightarrow \infty),$$

则称 X_n 依概率收敛于 x , 记为 $X_n \xrightarrow{P} x$ 。

定理 AEP (渐近均分性)

设 $X_1, \dots, X_n$ 为 i.i.d. $\sim p(x)$, 则

$$-\frac{1}{n} \log p(X_1, \dots, X_n) \xrightarrow{P} H(X).$$

证明:

$$\begin{aligned} -\frac{1}{n} \log p(x_1, \dots, x_n) &= -\frac{1}{n} \log(p(x_1) \cdots p(x_n)) \\ &= -\frac{1}{n} \sum_{i=1}^n \log p(x_i) \xrightarrow{P} -\mathbb{E}[\log p(X)] = H(X). \end{aligned}$$

最后一步由弱大数定律得出。 □

2.2 典型集**定义 典型集**

关于 $p(x)$ 的**典型集** $A_\varepsilon^{(n)}$ 为序列 $(x_1, \dots, x_n) \in \mathcal{X}^n$ 的集合, 满足

$$2^{-n(H(X)+\varepsilon)} \leq p(x_1, \dots, x_n) \leq 2^{-n(H(X)-\varepsilon)}.$$

定理 典型集的性质

(a) 若 $(x_1, \dots, x_n) \in A_\varepsilon^{(n)}$, 则

$$H(X) - \varepsilon \leq -\frac{1}{n} \log p(x_1, \dots, x_n) \leq H(X) + \varepsilon.$$

(根据定义直接得到。)

(b) 当 n 充分大时, $\Pr\{A_\varepsilon^{(n)}\} \geq 1 - \varepsilon$ 。

(c) $|A_\varepsilon^{(n)}| \leq 2^{n(H(X)+\varepsilon)}$ 。

证明:

$$1 = \sum_{\mathcal{X}^n} p \geq \sum_{A_\varepsilon^{(n)}} p \geq |A_\varepsilon^{(n)}| \cdot 2^{-n(H(X)+\varepsilon)}.$$

(d) 当 n 充分大时, $|A_\varepsilon^{(n)}| \geq (1 - \varepsilon) \cdot 2^{n(H(X) - \varepsilon)}$ 。

证明:

$$1 - \varepsilon < \Pr\{A_\varepsilon^{(n)}\} = \sum_{A_\varepsilon^{(n)}} p \leq |A_\varepsilon^{(n)}| \cdot 2^{-n(H(X) - \varepsilon)}.$$

总结: $|A_\varepsilon^{(n)}| \doteq 2^{nH(X)}$ 。

2.3 AEP 的推论: 数据压缩

$|A_\varepsilon^{(n)}| \leq 2^{n(H(X) + \varepsilon)}$, 因此用 $\lceil n(H(X) + \varepsilon) \rceil$ bits 即可编码典型集中的序列。

编码方案:

- 典型集中序列: 前缀 $0 + a_1 a_2 \cdots$ ($\leq \lceil n(H(X) + \varepsilon) \rceil$ bits);
- 非典型集序列: 前缀 $1 + b_1 b_2 \cdots$ ($\leq \lceil n \log |\mathcal{X}| \rceil$ bits)。

期望码长:

$$\begin{aligned} \frac{1}{n} \sum p(x_1, \dots, x_n) l(x_1, \dots, x_n) &\leq \frac{1}{n} \left(1 + n(H(X) + \varepsilon) + 1 + \varepsilon(1 + n \log |\mathcal{X}| + 1) \right) \\ &= H(X) + \varepsilon(1 + \log |\mathcal{X}|) + \frac{2}{n}(1 + \varepsilon). \end{aligned}$$

第 3 章 信源编码

3.1 编码定义

定义 信源编码

编码为一个映射

$$C: \mathcal{X} \rightarrow D^*, \quad x \mapsto C(x),$$

其中 $D = \{0, 1, \dots, D-1\}$, D^* 为 D 上有限长度字符串的全体。

例 3.1.1. X 取值 1, 2, 3, 4, 概率 $\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}$, 编码 0, 10, 110, 111, 码长 1, 2, 3, 3。

期望码长

$$L(C) = \sum p(x) l(x) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = 1.75 = H(X).$$

问题：什么是好的信源编码？比较以下四种编码方案：

X	奇异	非奇异但非唯一可译	唯一可译但非即时	即时码
1	0	0	10	0
2	0	010	00	10
3	1	01	11	110
4	1	10	110	111

即时码满足 Kraft 不等式： $2^{-1} + 2^{-2} + 2^{-3} + 2^{-3} = 1$ 。

3.2 最优码长

定理 最优码长下界

对满足 Kraft 不等式 $\sum 2^{-l_i} \leq 1$ 的编码，期望码长满足

$$L = \sum p_i l_i \geq H(X) = H(p_1, \dots, p_m).$$

证明：令 $S = \sum 2^{-l_i}$ ， $q_i = \frac{2^{-l_i}}{S}$ ，则

$$\begin{aligned}
 L - H(X) &= \sum p_i l_i + \sum p_i \log p_i \\
 &= - \sum p_i \log 2^{-l_i} + \sum p_i \log p_i \\
 &= - \sum p_i \log(q_i \cdot S) + \sum p_i \log p_i \\
 &= - \sum p_i \log q_i + \sum p_i \log p_i - \sum p_i \log S \\
 &= D(p \| q) - \log S \geq 0.
 \end{aligned}$$

等号条件： $L = H(X) \iff D(p \| q) = 0$ 且 $\log S = 0 \implies p_i = q_i = 2^{-l_i}$ 且 $\sum 2^{-l_i} = 1$ (即 $S = 1$)。□

3.3 Kraft 不等式

定理 Kraft 不等式

对于 $\{0, 1\}$ 上的即时码，码字长度 $l_1, \dots, l_m$ 必须满足

$$2^{-l_1} + 2^{-l_2} + \dots + 2^{-l_m} \leq 1.$$

反之，若给定一组长度满足此不等式，则存在相应长度的即时码。

证明 (必要性): 不妨设 $l_1 \leq l_2 \leq \dots \leq l_m$ 。考虑深度为 l_m 的完全二叉树。码字 i 对应第 l_i 层的某个节点, 其子树占据第 l_m 层的 $2^{l_m-l_i}$ 个叶子。即时码要求各子树不重叠, 故

$$2^{l_m-l_1} + 2^{l_m-l_2} + \dots + 2^{l_m-l_m} \leq 2^{l_m}.$$

两边除以 2^{l_m} 即得 Kraft 不等式。 $\square$

3.4 Shannon 码

设 $p_1 \geq p_2 \geq \dots \geq p_m$, 令 $l_i = \lceil \log(1/p_i) \rceil$ 。

累积分布 $F_i = \sum_{k < i} p_k$, $F_1 = 0$, $F_2 = p_1$, $F_3 = p_1 + p_2$, $\dots$

编码方案: 对 $F_i \in [0, 1)$ 进行二进制展开, 保留前 l_i 位作为 i 的码字。

例 3.4.1. $p = (\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8})$, $l = (1, 2, 3, 3)$, $F = (0, \frac{1}{2}, \frac{3}{4}, \frac{7}{8})$ 。

码字: 0, 10, 110, 111。

即时性证明: 若 $i < j$,

$$F_j - F_i = \sum_{k=i}^{j-1} p_k \geq p_i \geq 2^{-l_i}.$$

若 F_i 是 F_j 的前缀, 则 $F_j - F_i \leq 2^{-(l_i+1)} + 2^{-(l_i+2)} + \dots < 2^{-l_i}$, 矛盾。

码长:

$$L = \sum p_i l_i = \sum p_i \lceil \log(1/p_i) \rceil < \sum p_i (\log(1/p_i) + 1) = H(X) + 1.$$

分组编码: $X_1^n = X_1 X_2 \dots X_n$, $L_n(X_1^n) < H(X_1^n) + 1 = nH(X) + 1$, 故

$$\frac{1}{n} L_n(X_1^n) < H(X) + \frac{1}{n}.$$

3.5 Huffman 码

例 3.5.1. X 取 5 个值, 概率 0.25, 0.25, 0.2, 0.15, 0.15。

Huffman 编码过程 (每步合并最小概率): 合并 $0.15 + 0.15 = 0.3$, 然后 $0.2 + 0.25 = 0.45$, 再 $0.3 + 0.25 = 0.55$, 最后 $0.45 + 0.55 = 1$ 。

码字: 01, 10, 11, 000, 001。

引理 最优即时码的结构性质

对任意一个分布，均存在满足如下性质的最优即时码：

- 1) 若 $p_j > p_k$ ，则 $l_j \leq l_k$ 。
(反证法：交换 $C(x_j)$ 和 $C(x_k)$ ， $l(C) - l(C') = (p_j - p_k)(l_j - l_k) > 0$ 。)
- 2) 最长的两个码字具有相同的长度 ($l_{m-1} = l_m$)。
- 3) 最长的两个码字仅在最后一位上有区别。

Huffman reduction: 设 $\bar{p} = (p_1, \dots, p_m)$, $p_1 \geq p_2 \geq \dots \geq p_m > 0$ 。令 $\bar{p}' = (p_1, \dots, p_{m-2}, p_{m-1} + p_m)$ 。

设 $C_{m-1}^*(\bar{p}')$ 为 $\bar{p}'$ 的最优即时码， $C_m^*(\bar{p})$ 为 $\bar{p}$ 的典则最优即时码（满足引理中性质 3）。

3.6 Shannon-Fano-Elias 编码

设 X 取值于 $\mathcal{X}$ ，概率分布 $p(x)$, $p_1, \dots, p_m$ 。

$$F_i = \sum_{j < i} p_j + \frac{p_i}{2}, \quad l_i = \lceil \log(1/p_i) \rceil + 1.$$

注意这里与 Shannon 码不同， F_i 多加了 $p_i/2$ 。

编码方案：取 F_i 的前 l_i 位比特。

命题 Shannon-Fano-Elias 码长

$$H(X) + 1 \leq L(C) \leq H(X) + 2.$$

分组编码： $X_1, \dots, X_n$, $X_i \sim X$, i.i.d., 则

$$H(X_1^n) \leq l(C(x_1, \dots, x_n)) \leq H(X_1^n) + 2,$$

从而

$$H(X) \leq \frac{l(C(x_1, \dots, x_n))}{n} \leq H(X) + \frac{2}{n}.$$